ChatGPT

# 중고차 플랫폼 가격·감가 예측을 위한 피처 전수 설계와 근거 문헌

## 요약

이 보고서는 “동일차량 단위(예: VIN)로 정확히 묶기 어렵고, 세대 구분도 불완전한 상황”을 전제로, 중고차 가격/감가(잔존가치)를 **코호트 기반(cohort-based)** 으로 설명·예측하기 위해 우리가 논의한 **전체 후보 피처(가능한 것 전부)** 를 구조화하고, 각 피처의 **지표 정의·방향성·데이터 타입·전처리·역할(학습/메타/설명/타깃)** 을 정리한다. 또한 각 피처 군이 왜 가격 형성에 필요한지에 대한 경험적 근거를 **학술·산업·공식 문서** 중심으로 수집해 연결한다. [1]

핵심은 다음 3층 구조다.
(1) **차량·코호트의 “기본 가치(베이스)”**: 제조사/모델/트림/파워트레인 + 신차 기준가 등은, 특성이 다른 상품의 가격이 “특성의 묶음(hedonic attributes)”으로 결정된다는 고전적 헤도닉 가격이론의 출발점이다. [2]
(2) **상태·신뢰의 “리스크 조정(프리미엄/패널티)”**: 사고/특수이력, 소유/용도, 정비 이력은 중고차 시장의 정보비대칭(‘레몬시장’)을 줄이거나 키우며 가격에 반영된다. [3]
(3) **시장 노이즈·시간요인의 “정규화·강건화(robustification)”**: 로그 변환, 윈저라이징/트리밍, 코호트 상대화, 계절조정(X-13ARIMA-SEATS) 등은 실제 업계 지수 산정에도 쓰이는 표준적 노이즈 저감 방식이며, 구현 시 하이퍼파라미터의 관행 범위가 존재한다. [4]

마지막으로 “설명 레이어(explanation labels)”는 모델 성능이 아니라 **제품 신뢰·전환(CTR→문의→계약)** 을 좌우한다. 특히 온라인 중고차 시장에서는 (a) 연식/주행거리의 **구간 경계에서 가격 불연속**, (b) 매물가와 실거래가의 괴리, (c) 첫 제안가 앵커링과 참조가격(reference price) 효과가 반복적으로 관측된다. 이는 설명 피처(“왜 비싸/싼가”)와 피처 엔지니어링(버킷, 스무딩, 시간/시장 효과 분리)의 직접 근거가 된다. [5]

## 문제 정의와 데이터 파이프라인

중고차 가치 예측을 “현재 시세 맞추기”로만 정의하면, 동일차량 매칭이 어려운 환경(차대번호/VIN 미확보·세대 미확정·중복 매물)에서 학습 신호가 약해진다. 대신 다음 형태가 실무적으로 안정적이다:
**(A) 코호트(유사 상품군) 기준선 + (B) 차량 상태·이력에 따른 조정 + (C) 노이즈 강건화 + (D) 설명 레이어**. [6]

특히 “매물 데이터(listing)”는 “거래 데이터(transaction)”가 아니며, 광고가가 판매가보다 높게 관측될 수 있고(가격 인하 후 판매), 중복 재등록/알고리즘 게임(홍보 목적 반복 등록) 문제도 존재한다. 따라서 메타데이터 기반의 중복·이상탐지와, 강건 통계/스무딩이 필요하다. [7]

```
flowchart TD
  A[Raw Inputs\n- Listing pages & seller text\n- Inspection/condition reports\n-
Optional: macro series (rates/oil)\n- Optional: external indices] -->
B[Ingestion & Metadata\n- source_platform/listing_id/url\n- snapshot_date\n-
raw_text fields]
  B --> C[Normalization\n- make/model/trim string normalize\n- time features
```

```
(age, reg quarter)\n- categorical cleanup\n- unit normalization (km, currency)]
  C --> D[Quality & Robustification\n- dedupe (url/text/fingerprint)\n- outlier
rules (price/odo)\n- winsorize/clip/log transforms]
  D --> E[Cohort Construction\n- cohort_key / relaxed_key\n- cohort aggregates
(median/IQR)\n- cohort-relative derived features]
  E --> F[Modeling\n- price or depreciation target\n- robust loss / quantile /
tree/linear]
  F --> G[Explanation Layer\n- pos/neg labels\n- human-readable reasons\n-
confidence & caveats]
  G --> H[Product Surfaces\n- pricing guidance\n- comparable cohort
distribution\n- trust signals (documents, report quality)]
```

## 피처 그룹의 목적과 가격 형성 논리

아래 그룹들은 "중고차 가격 = (상품 특성) + (품질/리스크) + (정보/신뢰) + (시장/행동 노이즈)"라는 구조를 데이터 관점에서 분해한 것이다. 헤도닉 가격이론은 상품이 '특성들의 묶음'으로 거래되며 관측가격이 그 특성의 암묵가격을 포함한다는 틀을 제공한다. [2]

- **코호트/차량 식별(cohort/vehicle id)**: 동일차량 매칭이 어렵다면, 최소한 "동급 정의"를 데이터로 고정해야 한다. 트림/파워트레인/구동/변속 등은 동급 내 가격 수준의 1차 분산을 줄인다(헤도닉/ML 연구에서 기본 입력). [8]
- **시간(time)**: 감가는 '차량 나이'의 함수인 동시에, "등록연도 경계(연식)"처럼 사람이 인지하는 구간 단위(연도/분기/반기)에서 불연속이 나타날 수 있어 버킷이 실증적으로 의미가 있다. [9]
- **주행(mileage)**: 마모/잔존수명/고장확률의 대리변수로 가격에 일관된 음(-)의 효과가 관측된다. 매물지수 산정에서도 "주행거리 보정"을 별도로 수행할 만큼 구조적 요인이다. [10]
- **사고(accident)**: 사고는 (a) 실제 품질 리스크(수리 품질·구조 손상)와 (b) 시장의 '사고차 기피' 행동이 합쳐져 가격 패널티를 만든다. 한국의 공인 양식은 "사고 이력 인정 범위(주요 골격 vs 외판 단순수리)"를 규정해 데이터 표준화의 근거를 제공한다. [11]
- **소유(ownership)**: 소유자 수는 관리 일관성/품질 불확실성에 대한 신호로 쓰이며, 일부 실증 연구에서는 이전 소유자 수 증가가 가격 하락(또는 비선형 하락)과 연관된다. [12]
- **용도(usage)**: 렌트/영업/법인 운행은 평균 주행 패턴, 운행강도, 사고·정비 리스크의 상이함 때문에 시장에서 별도 디스카운트 요인이 된다(특히 리테일에서 선호도 하락으로 반영). [13]
- **정비(maintenance)**: 정비이력은 '숨은 상태'에 대한 정보비대칭을 완화하는 장치다. 차량 이력개시(VHR)가 판매 효율(재고기간)과 품질 매칭 개선에 영향을 준다는 실증은, 정비/이력 피처가 단순 "장식"이 아니라 가격·판매행동에 개입함을 뒷받침한다. [14]
- **옵션(options)**: 고급 옵션/장비 데이터는 예측력을 유의미하게 개선할 수 있다(특히 트림만으로 장비 구성이 완전히 설명되지 않을 때). 다만 고차원 희소성 때문에 전처리(해싱/희소 벡터 압축)와 품질 관리가 핵심이다. [15]
- **코호트 상대 파생(cohort-relative derived)**: 개별 수치의 절대값보다 "동급 대비 편차"가 노이즈에 강하고 설명에 유리하다. 실제 업계 지수도 믹스/주행/계절을 분리해 '비교가능한 지표'를 만들기 때문에, 코호트 상대화는 실무적 설계다. [16]
- **메타데이터(metadata)**: 재현성/감사(audit)/신뢰를 위해 필요하지만, 모델이 "플랫폼/크롤러 특성"을 학습하는 누수(leakage) 위험이 있어 학습 입력에서는 원칙적으로 분리한다(대신 품질관리·중복·샘플링·후처리에 사용). [17]
- **설명 라벨(explanation labels)**: 온라인 시장의 가격은 "인지적 구간(연식/주행 1만km 경계)", "첫 앵커(제시가/첫 제안)" 같은 행동 요인에 의해 해석되며, 설명 라벨은 이를 제품 언어로 번역한다. [18]

# 피처 전수 사양서

표의 **효과 방향성**은 "가격(또는 잔존가치)" 기준이다: **(+) 가격↑/감가↓**, **(-) 가격↓/감가↑**, **(±) 시장·세그먼트·상호작용에 따라 달라질 수 있음**. 다수 연구에서 연식·주행거리 증가가 가격에 음(-)의 관계를 보이며, 사고 이력은 추가 할인으로 관측되는 것이 일반적이라는 점을 기본 가정으로 둔다. [19]

또한 **Role**은 다음 중 하나로 표기한다.
- **Train**: 모델 학습 입력
- **Target/Derived**: 타깃(라벨) 또는 타깃 파생(학습 입력으로 쓰면 누수)
- **Meta**: 추적·품질·조인/감사용
- **Explain**: UI/리포트 설명용(학습 입력보다는 규칙/후처리) [20]

### 코호트/차량 식별 그룹

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `vehicle_id` | 내부 조인 키(차량 엔티티) | string/id | 모델 입력 제외(고유키), 품질/조인용만 | (±) | Meta |
| `cohort_key` | `make+model+trim+powertrain` 등 코호트 식별자 | string | 정규화 문자열 조합, 버전관리 | (±) | Meta/Train(계모형) |
| `cohort_key_relaxed` | 샘플 부족 시 완화 코호트(예: trim 제외) | string | 규칙 기반 fallback | (±) | Meta |
| `make` | 제조사 | categorical | 표준명 매핑, 오탈자/병기 통합 | (±) 브랜드 프리미엄/선호도 | Train |

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `model` | 모델명 | categorical | 표준명 매핑(세부트림 표기 분리) | (±) | Train |
| `trim` | 트림(등급) | categorical | 정규화(공백/특수문자/패키지 분리), 희소도 점검 | (±) 일반적으로 상위 트림 (+) | Train |
| `powertrain` | 파워트레인(가솔린/디젤/HEV/EV 등) | categorical | 표준 카테고리, 연료타입과 중복 허용 | (±) | Train |
| `fuel_type` | 연료 타입(세부) | categorical | powertrain과 교차검증, 누락 시 `unknown` | (±) | Train |
| `drive_type` | 구동(2WD/4WD/AWD) | categorical | 표준화, 트림과 상호작용 고려 | (±) 지역/세그먼트 의존 | Train |
| `transmission` | 변속기(AT/CVT/MT 등) | categorical | 표준화 | (±) | Train |

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `engine_displacement_cc` | 배기량(cc) | numeric | 로그/표준화, 이상값 클리핑 | (±) 차급 따라 | Train |
| `base_price_new` | 신차 기준가(옵션 포함 가능하면 최선) | numeric | 로그, 인플레이션/연도 보정(선택) | (+) 기준가 ↑ → 절대가격↑, 감가율은 (±) | Train/ Target normali |

### 시간 그룹

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `vehicle_age_days` | `snapshot_date - first_registration_date` (일) | numeric | 월/년 변환, 클리핑(0 미만 제거) | (-) | Train |
| `vehicle_age_months` | 차령(개월) | numeric | 구간화(예: 0–12, 13–24…), 스플라인/GAM | (-) 비선형 가능 | Train |
| `vehicle_age_years` | 차령(년) | numeric | `vehicle_age_months/12` | (-) | Train |
| `first_reg_year` | 최초등록 연도 | categorical/ int | 연도 버킷, 원-핫 | (±) “연식 경계” 효과 | Train |

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `first_reg_half` | 최초등록 반기(H1/H2) | categorical | H1/H2로 단순화 | (±) | Train |
| `first_reg_quarter` | 최초등록 분기(Q1–Q4) | categorical | Q 버킷 | (±) | Train |
| `first_reg_month` | 최초등록 월(1–12) | categorical | 원-핫 또는 순환 인코딩(sin/cos) | (±) | Train |

### 가격/감가 기준 그룹

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `current_listing_price` | 현재 관측 매물가(스냅샷) | numeric | 로그, 이상치 처리(허위/급매), 통화 단위 | n/a | Target/Meta |
| `depr_abs` | `base_price_new - current_listing_price` | numeric | 0 하한, 로그(선택) | n/a | Target/Derived |

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `depr_rate` | `depr_abs / base_price_new` | numeric | 클리핑([0,1] 근방), 로짓 변환(선택) | n/a | Target/ Derived |
| `log_current_price` | `log(current_listing_price)` | numeric | 로그(필수 후보), 0/결측 처리 | n/a | Target/ Derived |
| `log_base_price_new` | `log(base_price_new)` | numeric | 로그 | (±) | Train (스케일 보정) |
| `price_to_new_ratio` | `current_listing_price / base_price_new` | numeric | 로그/비율 안정화 | n/a | Target/ Derived |

### 주행 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `odometer_km` | 누적 주행거리(km) | numeric | 로그(선택), 1%/99% 윈저라이즈, 버킷 | (-) | Train | 주행거리 증가는 가치 하락의 대표 요인. [39] |
| `annual_mileage_km` | `odometer_km / vehicle_age_years` | numeric | 0/저차령 분모 처리, 클리핑 | (-) 과주행이면 더 (-) | Train | 차령과 함께 마모/수명 대리 변수로 작동. [32] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `monthly_mileage_km` | `odometer_km / vehicle_age_months` | numeric | 위와 동일 | (-) | Train | 동일. [30] |
| `mileage_residual` | 기대 주행거리 대비 잔차 (예: 코호트·차령 기반) | numeric | 코호트 평균/중앙값 기반, 스무딩 | (+) 잔차 <0면 방어 / (-) 잔차>0면 감가 | Train | 업계 지수도 주행거리 보정을 수행('mileage adjustment'). [40] |
| `mileage_bucket` | 주행거리 구간(예: 0–1만, ...) | categorical | 1만km 단위 등 버킷 | (±) | Train/ Explain | 1만km 경계에서 가격 불연속이 관측됨(버킷이 행동적으로 의미). [34] |
| `is_high_mileage` | 과주행 플래그(잔차/버킷 기준) | boolean | 임계값(예: +1σ 또는 +p75) | (-) | Train/ Explain | 주행거리/차령 상호작용의 비선형을 단순화. [41] |
| `is_low_mileage` | 저주행 플래그 | boolean | 임계값(예: -1σ 또는 <p25) | (+) | Train/ Explain | 동일. [32] |

### 사고 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `has_accident` | 사고 이력 존재 여부 | boolean | 평가서에서 추출, 결측 =unknown 처리 | (-) | Train/ Explain | 사고·손상은 평균적으로 가격을 하락시킴. [42] |
| `accident_count` | 사고/수리 건수 | numeric | 상한 캡, 로그(선택) | (-) 누적 커질수록 | Train | 이력 많은 차량은 불확실성 증가. [43] |
| `accident_severity` | 무사고/경미/패널교환/구조손상/침수 등 | categorical | 공인평가서 룰로 표준화 | (-) 심각할수록 | Train/ Explain | 한국 공인 양식은 "주요 골격 사고" 인정 범위를 규정. [44] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `accident_front` | 전면 관련 손상 | boolean | 부위 체계 매핑 | (-) | Train/Explain | 부위·유형 표준화 근거(점검기록부 부위 정의/판정 기준). [45] |
| `accident_rear` | 후면 관련 | boolean | 동일 | (-) | Train/Explain | 동일. [45] |
| `accident_left` | 좌측면 | boolean | 동일 | (-) | Train/Explain | 동일. [46] |
| `accident_right` | 우측면 | boolean | 동일 | (-) | Train/Explain | 동일. [46] |
| `accident_side` | 좌/우 통합 측면 | boolean | left/right OR | (-) | Train/Explain | 측면 손상은 구조/도어/쿼터 관련 이력으로 인지될 수 있음. [45] |
| `accident_roof` | 루프 패널 손상 | boolean | 루프 관련 플래그 | (-) (구조 의심) | Train/Explain | 루프/쿼터/사이드실은 절단·용접 시 사고 표기. [45] |
| `accident_pillar` | 필러 손상 | boolean | 필러 플래그 | (-) (구조) | Train/Explain | 주요 골격·필러는 사고 인정 범위에서 중요. [45] |
| `accident_roof_pillar` | 루프/필러 통합 | boolean | roof OR pillar | (-) | Train/Explain | 동일. [45] |
| `frame_damage` | 주요 골격 손상(프레임) | boolean | 공인평가서 기준 | (--) 강한 (-) | Train/Explain | “사고이력 인정=주요 골격 판금/용접/교환” 규정. [47] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `structural_damage` | 구조손상(프레임 포함 상위) | boolean | frame과 중복 허용(후에 축소) | (--) | Train/Explain | 구조손상은 시장에서 가장 큰 리스크 신호. [42] |
| `flood_damage` | 침수 | boolean | 특수이력 분리 | (--) | Train/Explain | 특수이력은 정보비대칭·리스크로 강한 디스카운트. [43] |
| `replace_hood` | 후드 교환 | boolean | 공인평가서 교환/판금 추출 | (-) (대체로 경미) | Train/Explain | 외판(후드 등)은 단순 수리로 사고에 포함되지 않을 수 있음(한국 표준). [47] |
| `replace_trunk` | 트렁크리드 교환 | boolean | 동일 | (-) | Train/Explain | 외판 범주 근거. [47] |
| `replace_fender` | 휀더 교환 | boolean | 동일 | (-) | Train/Explain | 동일. [47] |
| `replace_door` | 도어 교환 | boolean | 동일 | (-) | Train/Explain | 동일. [47] |
| `replace_bumper_front` | 전범퍼 교환 | boolean | 부품 매핑 | (-) (경미) | Train/Explain | 범퍼/외판은 “사고”와 구분되는 경우가 있음. [47] |
| `replace_bumper_rear` | 후범퍼 교환 | boolean | 동일 | (-) | Train/Explain | 동일. [47] |
| `repair_quarter_panel` | 쿼터패널 수리/교환 | boolean | 절단·용접 여부까지 가능하면 분리 | (-)~(-- ) | Train/Explain | 쿼터/루프/사이드실은 절단·용접 시 사고 표기. [47] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `repair_panel_count` | 외판 수리·교환 개수 | numeric | 상한 캡 | (-) | Train | 외판 개수는 '경미 손상 누적'의 신호. [48] |
| `major_panel_repair_count` | 주요 부위(쿼터/루프/필러 등) 수리 개수 | numeric | 상한 캡 | (--) | Train | 주요 부위는 시장 리스크가 더 큼. [47] |
| `repair_cost_total` | 수리비 총액(가능 시) | numeric | 로그, 윈저라이즈, 결측률 점검 | (-) 비용↑ → 가치↓(대체로) | Train(품질 좋을 때)/ Meta | 이력 정보가 가격·판매 효율에 가치를 가진다는 실증. [49] |
| `repair_cost_bucket` | 수리비 구간 | categorical | 버킷화 | (-) | Train/ Explain | 설명용("누적 수리비 규모"). [50] |

### 소유권 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `owner_count` | 누적 소유자 수 | numeric | 상한 캡(예: 5+), 버킷 병행 | (-) 또는 (±) | Train | 이전 소유자 수 증가가 가격 감소(비선형)와 연관된 사례 연구. [12] |
| `is_single_owner` | `owner_count==1` | boolean | 파생(중복 허용) | (+) | Train/ Explain | 정보비대칭 완화·이력 신뢰와 연결(이력 정보의 가치). [51] |
| `is_multi_owner` | `owner_count>=3` 등 | boolean | 규칙 기반 파생 | (-) | Train/ Explain | 동일. [52] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `owner_count_bucket` | 1/2/3–4/5+ 등 | categorical | 버킷화 | (-) | Train/ Explain | 비선형을 설명가능한 규칙으로 단순화. [12] |

### 용도 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `usage_type` | private/ corporate/ rental/ commercial/ mixed | categorical | 표준 카테고리, 결측 =unknown | (±) 보통 rental/ commercial (-) | Train | 상용 목적 차량의 잔존가치 요인 분석에서 용도 차이가 변수 영향에 차이를 보임. [53] |
| `has_rental_history` | 렌트 이력 | boolean | usage_type에서 파생 가능 | (-) | Train/ Explain | 정보비대칭/품질 불확실성 프레임에서 리스크 신호. [43] |
| `has_commercial_use` | 영업용(택시/ 배달 등) | boolean | 동일 | (-) | Train/ Explain | 상용 목적 차량은 주행/연식의 영향 구조가 다를 수 있음. [53] |
| `has_corporate_use` | 법인/리스/플릿 성격 | boolean | 동일 | (±) | Train/ Explain | 시장에서 '개인 자가용' 대비 선호 차이가 발생 가능(이력정보 가치). [51] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `is_private_use_only` | 순수 자가용 플래그 | boolean | 파생 | (+) | Train/ Explain | 불확실성 감소(이력 정보가 판매 효율을 개선). [49] |
| `usage_change_count` | 용도 변경 횟수 | numeric | 상한 캡 | (-) | Train | 이력 복잡성은 불확실성 신호. [43] |

### 정비이력 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `has_maintenance_history` | 정비이력 존재 여부 | boolean | 평가서/정비기록 연계, 결측 처리 | (+) | Train/ Explain | 차량 이력(VHR) 제공이 판매 기간 단축·역선택 완화에 기여(이력의 가치). [49] |
| `maintenance_count` | 누적 정비 횟수 | numeric | 로그, 캡 | (±) 예방정비면 (+), 잦은 고장 수리면 (-) | Train | 품질 신호가 양면적이라 '패턴/유형 분리'가 중요. [51] |
| `maintenance_count_12m` | 최근 12개월 정비 횟수 | numeric | 윈저라이즈 | (±) | Train/ Explain | "최근성"이 신뢰/상태 신호로 작동. [54] |
| `maintenance_count_24m` | 최근 24개월 정비 횟수 | numeric | 동일 | (±) | Train | 동일. [49] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `days_since_last_maintenance` | 최근 정비 후 경과일 | numeric | 로그/캡 | (-) 길수록 불리(대체로) | Train/ Explain | 이력정보가 거래 효율/품질 매칭에 가치를 가진다는 실증과 정합. [49] |
| `maintenance_consistency_score` | 정비 주기 안정성(예: CV, gap entropy) | numeric | 표준화, 결측 시 0+missing flag | (+) 높을수록 | Train/ Explain | 이력·정비 기록은 정보비대칭 완화 장치로 해석 가능. [43] |
| `official_service_ratio` | 공식센터 정비 비중 | numeric | [0,1] 클리핑 | (+) | Train/ Explain | 규격화된 정비 기록은 신뢰 신호로 작동(이력정보 가치). [54] |
| `major_repair_history` | 엔진/미션 등 중대 수리 이력 플래그 | boolean | 정의 표준화 필요 | (±) | Train/ Explain | 성능·상태 점검/보증 구조에서 주요 장치 이슈가 민원과 연결됨. [55] |
| `major_repair_count` | 중대 수리 횟수 | numeric | 캡 | (±) | Train | 동일. [55] |
| `engine_oil_recent` | 엔진오일 최근 교체 | boolean | 기간/주행 기준 정의(예: 6개월/5천km) | (+) (약함) | Train/ Explain | '정비 최근성'의 저비용 신호(다만 trivial 가능). [49] |
| `transmission_oil_recent` | 미션오일 최근 교체 | boolean | 동일 | (+)~(±) | Train/ Explain | 주요 장치 리스크와 연결 가능. [55] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `brake_service_recent` | 브레이크 정비 최근성 | boolean | 동일 | (+) | Train/ Explain | 예방정비 성격. [49] |
| `tire_replaced_recent` | 타이어 최근 교체 | boolean | 동일 | (+) | Train/ Explain | 구매자 체감(즉시비용) 신호. [49] |
| `battery_replaced_recent` | 배터리 최근 교체 | boolean | 동일 | (+) (약함) | Train/ Explain | 단기 비용/신뢰 신호. [49] |
| `coolant_service_recent` | 냉각수/관련 정비 최근성 | boolean | 동일 | (+) (약함) | Train/ Explain | 예방정비 성격. [49] |

### 옵션/장비 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `has_adas` | ADAS(ACC/ LKA 등) 유무 | boolean | 트림/옵션 텍스트에서 추출, 결측 처리 | (+) 또는 (±) | Train | 장비(옵션) 정보가 예측오차를 유의미하게 개선. [25] |
| `has_sunroof` | 선루프 | boolean | 동일 | (±) 세그먼트 의존 | Train | 장비 정보의 예측력 개선 근거. [25] |
| `has_hud` | HUD | boolean | 동일 | (+) | Train | 동일. [25] |
| `has_avm` | 어라운드뷰 (AVM) | boolean | 동일 | (+) | Train | 동일. [25] |
| `has_navigation` | 내비게이션 | boolean | 동일 | (±) | Train | 장비 정보 중요성. [15] |
| `has_heated_seat` | 열선시트 | boolean | 동일 | (±) | Train | 동일. [25] |
| `has_ventilated_seat` | 통풍시트 | boolean | 동일 | (+) | Train | 동일. [25] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `seat_material` | 시트 재질(천/가죽 등) | categorical | 표준화 | (±) | Train | 장비/사양이 가격에 기여. [15] |
| `wheel_size_inch` | 휠 인치 | numeric | 캡/표준화 | (±) | Train | 장비·성능/크기 특성의 가격 기여. [56] |
| `ext_color` | 외장색 | categorical | 표준 색상 팔레트, 희소색 합치기 | (±) | Train/Explain | 일부 연구에서 색상 영향은 작거나 혼재. [57] |
| `int_color` | 내장색 | categorical | 동일 | (±) | Train | 동일. [57] |
| `option_count` | 옵션 개수(탑재 항목 수) | numeric | 캡/표준화 | (+) (약함~중) | Train | 장비 정보가 예측력 개선. [25] |
| `option_signature` | 옵션 멀티핫/해시 서명(세트) | string/high-dim | 해싱(예: 2^18–2^20), 희소벡터 | (±) | Train(고급) | 5만+ 옵션을 자동 전처리해 성능 개선(장비 고차원 처리 사례). [25] |

### 코호트 상대 파생 그룹

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `price_gap_vs_cohort_median` | `price - median(price \| cohort)` | numeric | 코호트 표본수 작은 경우 shrinkage | (±) | Train/Explain |
| `price_ratio_vs_cohort_median` | `price / median(price \| cohort)` | numeric | 로그비율 권장 | (±) | Train/Explain |

| feature name | description / metric | type | preprocessing | expected effect | role |
|---|---|---|---|---|---|
| `odometer_gap_vs_cohort` | `odometer - median(odometer \| cohort, age)` | numeric | age 조건부 중앙값 | (±) | Train/ Explain |
| `mileage_residual_vs_cohort` | `mileage_residual`의 코호트 표준화(z) | numeric | robust z (median/IQR) | (±) | Train/ Explain |
| `maintenance_score_vs_cohort` | 정비 점수의 코호트 대비 편차 | numeric | robust scaling | (±) | Train |
| `owner_count_vs_cohort_avg` | 소유자 수의 코호트 평균 대비 | numeric | 캡/표준화 | (±) | Train |
| `depr_rate_vs_cohort_median` | 감가율의 코호트 중앙값 대비 | numeric | robust scaling | (±) | Explain/ Diagnostics |

### 메타데이터 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `source_platform` | 수집처(플랫폼) | categorical | 표준화 | (±) | Meta | 소스별 매물가/정책 차이로 편향 가능 → 학습 제외 권장. [21] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `source_listing_id` | 원본 매물 ID | string | 조인·중복탐지키 | (±) | Meta | 중복/재등록 문제에서 ID의 중요성. [21] |
| `source_url` | 원본 URL | string | 정규화(파라미터 제거) | (±) | Meta | 동일. [21] |
| `trim_raw_text` | 트림 원문 텍스트 | text | NLP 정규화, 사전 기반 파싱 | (±) | Meta | 장비/트림 정보 전처리의 필요. [25] |
| `accident_raw_text` | 사고/특이사항 원문 | text | 규칙+모델 추출, 버전관리 | (±) | Meta | 공인 양식의 사고 정의를 기반으로 표준화. [47] |
| `maintenance_raw_text` | 정비 원문 | text | 동일 | (±) | Meta | 이력정보가 거래 효율에 가치. [49] |
| `crawl_job_id` | 수집 배치 ID | string | 운영 로그 | (±) | Meta | 품질·재현성. [40] |
| `snapshot_date` | 관측 시각 | date | 시계열 정렬, 인덱스 연동 | (±) | Meta/Train(시장효과) | 지수 산정·계절조정·시장효과에 필요. [35] |
| `inspection_report_url` | 성능/상태 점검 문서 링크 | string | 접근권한/만료관리 | (±) | Meta | 한국은 점검기록부/보증 체계 존재(소비자 보호). [44] |
| `image_urls` | 이미지 링크 배열 | array<string> | 해시/특징추출(선택) | (±) | Meta | 비전 기반 상태추정 확장 가능(본 범위 밖). [21] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examples |
|---|---|---|---|---|---|---|
| `seller_raw_text` | 판매자 설명 원문 | text | NLP(허위·강조 키워드) | (±) | Meta | 광고가/판매가 괴리 및 텍스트 조작 가능성. [21] |

### 설명 라벨 그룹

| feature name | description / metric | type | preprocessing | expected effect | role | source examp |
|---|---|---|---|---|---|---|
| `single_owner_label` | “1인 소유” 표시 | boolean | `owner_count==1` | (+) 신뢰 | Explain | 이력정보가 판매율/품질 칭 개선. [49] |
| `multi_owner_label` | “소유자 변경 많음” 표시 | boolean | `owner_count>=3` 등 | (-) | Explain | 동일. [5 |
| `rental_history_label` | “렌트 이력” | boolean | usage_type 기반 | (-) | Explain | 상용 목적 차량 특성 차이. [5 |
| `commercial_use_label` | “영업용 이력” | boolean | 동일 | (-) | Explain | 동일. [5 |
| `high_mileage_label` | “동급 대비 과주행” | boolean | mileage_residual 기준 | (-) | Explain | 주행거리 경계/구 행동 반 [59] |
| `low_mileage_label` | “동급 대비 저주행” | boolean | 동일 | (+) | Explain | 동일. [6 |
| `major_damage_label` | “구조/침수 등 중대 이력” | boolean | frame/flood 기준 | (--) | Explain | 한국 공 사고 인 범위 + 고 패널 근거. [4 |
| `maintenance_good_label` | “정비이력 양호” | boolean | 최근성+일관성+공식비중 | (+) | Explain | 이력 제 이 매칭/ 율 개선( 력 가치) [49] |

| feature name | description / metric | type | preprocessing | expected effect | role | source examp |
|---|---|---|---|---|---|---|
| `maintenance_weak_label` | “정비이력 부족” | boolean | 결측/최근성 낮음 | (-) | Explain | 정보비대칭(레몬 장) 프레과 정합. [43] |
| `recent_service_label` | “최근 정비 완료” | boolean | days_since_last_maintenance 임계 | (+) | Explain | 이력의 근성이 뢰 신호. [49] |
| `official_service_label` | “공식센터 정비” | boolean | official_service_ratio 임계 | (+) | Explain | 점검/보 체계에서 기록의 뢰가 중 [61] |

## 경험적 근거 문헌·리포트 요약과 매핑

아래는 본 보고서에서 각 피처 군(및 핵심 피처)에 연결해 사용한 근거 자료를 **국내/국외 혼합**으로 정리한 것이다. 각 항목은 “무엇을 발견했고 왜 관련 있는지”를 1–2문장으로 요약하며, 지역 범위·데이터·한계를 함께 적는다.

| source | scope | data | key findings & relevance | limitations |
|---|---|---|---|---|
| Rosen (1974) “Hedonic Prices and Implicit Markets” DOI: 10.1086/260169 | 글로벌(이론) | 이론/모형 | 차별화된 상품 가격을 ‘특성(속성)의 암묵가격 합’으로 설명하는 헤도닉 틀을 제시해, 코호트/사양/옵션 피처 설계의 이론적 기반이 된다. [62] | 이론적 틀이라 “중고차의 특정 변수” 크기를 직접 주지 않음 |
| Akerlof (1970) “The Market for ‘Lemons’” DOI: 10.2307/1879431 | 글로벌(이론+자동차 예시) | 이론(중고차 시장 예시) | 중고차 시장에서 정보비대칭이 역선택·품질 저하를 유발함을 보여주며, 사고/정비/이력(신뢰) 피처의 경제적 의미를 정당화한다. [63] | 고전 이론으로 현대 온라인 시장의 제도·데이터 환경은 별도 고려 필요 |
| (미국) 송정석·신준호·이동준 (2020) “미국 중고차 가격 결정요인” DOI: 10.17825/klr.2020.30.6.105 | 한국 연구(미국 시장 분석) | 2017년 미국 50개주 중고차 데이터 | 모델연도·마일리지(주행거리) 등 통제변수와 지역 소득을 포함해 가격결정요인을 실증. ‘시간·주행’이 기본 축임을 재확인하며, 지역/시장 효과(캘린더 타임/외생)도 고려할 여지를 준다. [64] | 논문 원문 전체 변수 설계/품질은 별도 확인 필요(요약 기반) |

| source | scope | data | key findings & relevance | limitations |
|---|---|---|---|---|
| Sharma et al. (2024) “Developing a used car pricing model… (MARS)” | 인도 [65] 중심 | 딜러 가격 데이터(논문) | 차령·주행거리·이전 소유자 수가 가격 하락을 유발하며, 관계가 비선형이어서 스플라인/MARS 같은 기법이 유효하다고 보고. ‘age/mileage/owner_count + 비선형 전처리’의 근거. [12] | 국가/시장 구조(규제·수요) 차이, 거래가 vs 제시가 여부 영향 |
| Morgan et al. (2025) “Used car life history…” | 영국 [66] | 3M+ 광고 데이터 | 광고가 기반 데이터는 판매가보다 높게 관측될 수 있고, 중복·재등록 및 고유 ID 부족 문제를 직접 언급. 메타데이터/중복탐지/강건화 필요성을 뒷받침한다. [21] | 판매(거래) 데이터가 아니라 광고 데이터라는 한계 |
| Huang, Liu, Luo (2021) “Vehicle History Reports and efficiency” DOI: 10.2139/ssrn.3976378 | 미국 [67] (리테일) | 딜러 매물 패널 + VHR 정책 변화 | 무료 VHR 제공이 판매까지의 시간(재고기간)을 유의미하게 줄이고, 역선택을 완화하며, 이력정보에 최소 $250 가치가 있다고 추정. 사고/소유/정비/특수이력 피처가 “가격·판매 효율”에 모두 영향을 줄 근거. [49] | 특정 리테일 채널·정책 변화 기반이라 일반화 주의 |
| CARFAX(2025) 사고 이력의 가격 영향(평균 -$500, severe -$1700) | 미국 [67] (리테일) | CARFAX 분석/도구 | 사고·손상 이력이 평균적으로 리테일 가격을 낮추며, 심각 손상에서 패널티가 더 크다고 제시. 사고 severity/부위 피처의 방향성과 설명 라벨 설계에 직접적. [68] | 수치가 특정 데이터/정의에 의존(시장·차종별 상이) |
| 국토교통부 고시/서식(별지 제82호) “중고자동차 성능·상태점검기록부” | 국토교통부 [69] / 대한민국 [70] | 법령 서식(공식) | ‘사고이력 인정’ 범위(주요 골격 판금/용접/교환)와 외판·범퍼 등 단순수리 구분 규칙을 명시해, 사고 부위/유형 피처 표준화의 법적 근거가 된다. [71] | 실제 현장 점검 품질 편차는 별도 문제 |
| 보험연구원(KIRI) (2024) 성능·상태점검 책임보험 제도 분석 | 보험연구원 [72] / 대한민국 [70] | 제도/민원/보험 통계 | 점검기록부 vs 실제 상태 불일치, 보증·보험 구조, 민원 유형 등을 분석해 “점검·정비·주요장치” 피처의 품질/신뢰 관리 필요성을 강화한다. [55] | 가격결정 계량 모형이 아니라 제도 분석 중심 |
| KAIST(2022) 상용 목적 차량 잔존가치 요인 | KAIST [73] / 대한민국 [70] | 승용·상용 중고차 데이터 회귀 | 주행거리·연식·부품교체·보증 등이 잔존가치에 유의미하며, 상용 목적 차량에서는 일부 요인 영향 구조가 달라질 수 있음을 보고. usage_type/상호작용 설계 근거. [53] | 데이터 범위/차종·표본 대표성 제약 가능 |

| source | scope | data | key findings & relevance | limitations |
|---|---|---|---|---|
| Englmaier et al. (2018) “Price Discontinuities…” DOI: 10.1287/mnsc.2016.2714 | 독일 [74] (온라인) | 유럽 대형 온라인 마켓 상세 field data | 등록연도 경계(1월 vs 전년 12월)·1만km 경계에서 가격이 불연속적으로 ‘툭’ 떨어지는 현상을 보고(제한된 주의/탐색 마찰). time bucket과 mileage bucket, 설명 라벨(“1만km 돌파”)의 실증 근거. [34] | 특정 시장/플랫폼, 거래가 아니라 게시/필드 데이터 성격 주의 |
| Manheim Used Vehicle Value Index 방법론(요약) | Cox Automotive [75] / 미국 [67] (도매) | 경매 거래 + 통계 절차 | 이상치 제거(가격·주행 2.6σ), 주행거리 회귀 보정, 24개월 롤링 가중치, X-13ARIMA-SEATS 계절조정 등 “현업 지수”가 노이즈를 줄이는 구체 절차를 공개. 코호트 상대화·강건화·계절조정의 실무 근거. [76] | 도매(auction) 지수로 리테일과 차이 |
| J.D. Power(2026) ALG Residual Value Awards 자료 | J.D. Power [77] / 미국 [67] | 거래 데이터+ALG 예측 프레임 | 잔존가치에 영향을 주는 변수로 mileage/condition, features/pricing, used supply, seasonality, macro 등을 명시. 피처 그룹(주행·상태·옵션·시장효과)의 존재 자체를 산업 표준 관점에서 확인. [78] | 구체 계수/영향 크기는 공개 자료에 제한 |
| Busse et al. (2009) NBER “Gasoline prices… new vs used” | 미국 [67] | 거래/시장 데이터(논문) | 유가 변화가 연비 수준별 중고차 상대가격과 수요에 유의미하게 반영됨을 보여, oil price 같은 외생 변수가 market noise가 아니라 구조적 설명변수임을 뒷받침. [79] | 연비·세그먼트 정의, 시기/제도 환경에 따라 효과 크기 변동 |
| NIST/SEMATECH EDA Handbook(윈저라이즈/트리밍) | National Institute of Standards and Technology [80] | 통계 핸드북 | heavy-tail/이상치가 평균을 왜곡할 때 median/trimmed/winsorized mean이 강건한 대안임을 설명. 중고차 가격·주행 데이터의 이상치 처리(윈저라이즈/트리밍) 근거. [81] | 응용 사례는 도메인별로 조정 필요 |
| Tversky & Kahneman (1974) DOI: 10.1126/science.185.4157.1124 | 글로벌(행동) | 실험/이론 | 불확실성 하에서 ‘앵커링과 조정’ 휴리스틱을 제시해, 제시가/첫 제안가가 협상·인지에 영향을 주는 설명 레이어의 기반. [82] | 일반 행동이론이라 시장 특수성은 별도 |

| source | scope | data | key findings & relevance | limitations |
|---|---|---|---|---|
| Schweinsberg et al. (2023) PNAS DOI: 10.1073/pnas.2218582120 | eBay [83] (협상) | 2,600만 건 협상 로그 | 첫 제안가가 판매가에 선형 앵커링 효과를 가지며, 동시에 결렬 위험은 비선형으로 변한다는 대규모 실증. 온라인 거래에서 '앵커·협상' 설명 라벨/피처 설계 근거. [84] | eBay 협상 구조 특수성(중고차 플랫폼과 동일하지 않을 수 있음) |
| Huang(2012/후속) 동태적 가격설정/학습(used-car dealership panel) | Harvard Business School [85] | 리딩 딜러의 패널 데이터 | 이질적 상품(used cars)에서 판매자/딜러가 판매 과정에서 수요를 학습하며 가격을 동적으로 조정하는 모델을 제시. 가격 변경 이력·재고기간이 중요한 이유를 정당화한다. [86] | 특정 딜러/채널 기반, 외삽 주의 |
| KAMA 웹진(이전등록/거래 구조 설명) | 한국자동차모빌리티산업협회 [87] / 대한민국 [70] | 국토교통부 이전등록 통계 해설 | '이전등록 건수'가 실제 판매대수와 다를 수 있음을 설명해, 통계 해석과 시장 규모 추정 시 주의점(데이터 정의)을 제공. [88] | 웹진 자료(연도 현재성/업데이트 확인 필요) |
| 대한상공회의소 이슈페이퍼(2024) | 대한상공회의소 [89] / 대한민국 [70] | 국토부 통계 인용 | 2022년 신차 등록(약 168만) 대비 중고차 거래(약 372만 건), 시장 규모(30조원+) 등을 제시해, 코호트·시장효과를 다루어야 할 "시장 크기/동학"을 제공. [90] | 보고서 목적이 수출/정책이라 가격모형 직접 근거는 제한 |
| CarGurus Price Trends(지수/트렌드 공개) | CarGurus [91] | 플랫폼 지표 | 최근 기간(예: 90일) 기준 가격 트렌드를 공개해, "캘린더 타임 효과"를 외부 지표로 보정하는 아이디어에 참고가 된다. [92] | 지표 정의/표본이 플랫폼에 종속 |

## 시계열·시장 노이즈 처리 기법과 구현 권고

여기서는 "과거 동일차량 패널이 없거나 불완전해도" 적용 가능한, **코호트 기반** 시간/노이즈 처리 기법을 정리한다. 특히 "중고차 지수 산정(현업)"에서 실제로 쓰이는 절차(이상치 제거, 주행거리 회귀 보정, 계절조정)가 좋은 출발점이다. [93]

| method | purpose | pros | cons | references | implementation notes / typical hyperparams |
|---|---|---|---|---|---|
| 로그 변환 `log(price)` | heavy-tail 완화, 선형성 개선 | 간단·효과 큼 | 0/결측 처리 필요 | 가격 분포 강건성 논의(평균 vs 중앙값), 현업 지수의 이상치 처리 맥락. [37] | `log(price)` 또는 `log(price/base_price_new)` 추천. 0은 `log1p`/하한 적용 |
| 윈저라이즈/트리밍 | 극단값 영향 축소 | 구현 쉬움, 강건 | 임계 선택이 민감 | NIST 핸드북이 윈저라이즈/트리밍 정의와 예시 제시. [81] | 보통 p1–p99 또는 p0.5–p99.5. 코호트별로 하면 더 안정적 |

| method | purpose | pros | cons | references | implementation notes / typical hyperparams |
|---|---|---|---|---|---|
| 이상치 제거(2.6σ 등) | 허위/오입력/급매 노이즈 제거 | 업계 지수에서도 사용 | 정규성 가정 위험 | Manheim은 가격·주행 편차가 모두 2.6σ 밖이면 이상치로 제거. [40] | 시작값: 2.5–3.0σ. 단, 코호트별/연식별로 표준화 후 적용 권장 |
| 코호트 기준선(연령×코호트 중앙값) | "동급 내 정상 범위"를 만든 뒤 잔차로 학습 | 동일차량 매칭 없어도 작동 | 표본 적은 코호트에서 불안정 | mix/주행/계절을 분리해 비교가능 지표를 만드는 Manheim 절차와 개념 유사. [40] | `median_price(cohort, age_bucket)` + IQR. n<30이면 상위 코호트/계층 shrinkage |
| 스무딩(LOESS/이동중앙값) | 연령-가격 곡선의 톱니 제거 | 해석 쉬움 | 과도 스무딩 위험 | 연식/주행 경계에서 불연속 존재(행동요인) → 스무딩 강도 조절 필요. [34] | LOESS span 0.2–0.4(초기). 이동중앙값 window 2–4주 또는 1–2개월 |
| 캘린더 타임 효과 분리 | 동일 차령이라도 시장 국면 차이를 반영 | 히스토리 없을 때도 `first_reg_*`로 대리 가능 | 진짜 시장효과는 snapshot_time 필요 | Manheim은 계절조정(X-13ARIMA)으로 time effect 분리. [35] | (a) `snapshot_date`로 월 고정효과, (b) 외부 지수(Manheim/CarGurus 등) 입력 |
| 계절조정(X-13ARIMA-SEATS) | 월별 계절성 제거(지수·시장수준) | 공문서/업계 표준 | 구현 복잡 | Manheim이 X-13ARIMA-SEATS로 계절조정을 수행한다고 명시. [40] | 최소 3–5년 월별 지표가 이상적. 이상치 플래그 함께(holiday/outlier) |
| 강건 손실(허버/퀀타일) | 이상치 많은 가격 데이터에서 안정 | 성능·안정성 | 튜닝 필요 | robust estimation 고전(허버)과, 자동차 가격 연구에서 quantile/penalized 방법 사용 사례. [94] | Huber δ: 표준화 잔차 기준 1–2. Quantile τ: 0.5(중앙), 0.25/0.75(구간) |
| 혼합효과/계층모형(mixed-effects) | 코호트별/트림별 랜덤효과로 부분풀링 | 소표본 코호트에 강함 | 구현·해석 비용 | 패널/고정효과 헤도닉 모델 사용 사례. [95] | 랜덤 인터셉트: (make/model/trim). 랜덤 슬로프: age, mileage |

| method | purpose | pros | cons | references | implementation notes / typical hyperparams |
|---|---|---|---|---|---|
| 패널/차분(DiD) | 정책/충격 전후 효과 분리 | 인과에 유리 | 동일 단위 추적 필요 | gasoline price 충격이 중고차 상대가격에 반영됨(시장 충격 사례). [96] | 동일 차종군을 연비 구간 treatment/control로 두고, 시점 교차로 DiD |
| 외생 변수(유가/금리) | 시장수준 변동 설명 | 설명력↑ | 데이터 연결 필요 | 유가가 연비별 중고차 가격에 큰 상대가격 변화를 유발. [26] | exog는 월 단위로 정렬. lag(1–3개월) 후보. 금리는 할부 접근성 변수를 대리 |

실무 권고(코호트·매물 기반 MVP 기준):
- **첫 릴리즈**는 "복잡한 시계열 예측"보다, `vehicle_age_*` + `first_reg_*` + (주행/사고/이력/정비/옵션)으로 **단면 모델 + 강건 전처리**를 만들고, `snapshot_date` 기반으로 시장효과를 후처리 보정하는 구조가 안정적이다. [97]
- **하이퍼파라미터의 안전한 시작값**: (a) 가격/주행 p1–p99 윈저라이즈, (b) 코호트 표본 n<30이면 상위 코호트로 shrinkage, (c) age는 스플라인/트리로 비선형 허용, (d) 사고는 severity 우선 + 구조/침수는 별도 강한 플래그 유지. [98]

## 마켓플레이스 행동 패턴과 피처/설명 레이어 시사점

온라인 중고차 시장에서는 "차량의 물리적 상태" 외에도 "사람의 판단 규칙"이 가격·협상·판매기간에 영향을 준다. 이를 설명 라벨과 피처 엔지니어링으로 흡수하면, 예측 성능뿐 아니라 **전환/신뢰** 지표가 개선될 가능성이 크다. [99]

첫째, **구간 경계에서의 불연속(coarse information processing)**. 온라인 중고차 가격은 연식(등록연도) 경계나 1만km 단위에서 '툭' 떨어지는 불연속이 관측된다. 이는 "연속값을 평활하게 넣는 것"만으로는 포착이 어렵고, `first_reg_year/half/quarter` 및 `mileage_bucket` 같은 버킷 피처가 실증적으로 정당화된다. [34]

둘째, **가격 조정·재고기간·참조가격 효과**. 딜러/플랫폼은 판매 과정에서 수요를 학습하며 가격을 내리거나 전략적으로 조정하는데, 이는 `snapshot_date`별 가격 변경 이력(추후 확장 피처)과 "재고기간(Days-to-Turn)" 같은 운영 지표를 모델/설명에 연결해야 하는 이유다. 패널 데이터 기반 연구는 동태적 가격설정이 실제 사용되고, 학습(learning) 가치가 존재함을 보여준다. [86]

셋째, **협상에서의 앵커링**. 첫 제안가(또는 제시가)는 협상 결과의 기준점이 되며, 대규모 협상 로그에서도 첫 제안이 판매가에 선형적 앵커링 효과를 가지는 것이 관측된다. 따라서 "현재 가격이 높은/낮은 이유" 설명에 `price_gap_vs_cohort_median` 같은 상대 지표와 함께, "시장 평균 대비 위치"를 앵커링 프레임으로 제시하는 것이 설득력을 높일 수 있다. [100]

넷째, **이력정보(사고/정비/소유)의 '가격'뿐 아니라 '판매 효율' 효과**. VHR 제공이 판매까지의 시간을 줄이고 역선택을 완화했다는 실증은, 사고/정비/소유 피처가 "가격 예측"과 "판매 가능성/판매기간" 양쪽에 유효하다는 것을 의미한다. 제품적으로는 (a) 가격 설명 라벨, (b) 리스크/신뢰 배지, (c) 빠른 판매 확률(추후)로 확장할 수 있는 근거가 된다. [101]

실무적으로 추천되는 설명 라벨 구성은 다음의 '사람이 납득하는 문장' 형태다:
- **감가 요인(neg)**: "주요 골격 사고/침수 이력", "동급 대비 과주행", "소유자 변경 많음", "정비 이력 부족" 등 [102]
- **가격 방어 요인(pos)**: "무사고/구조손상 없음", "동급 대비 저주행", "정비 이력 존재 및 최근 정비", "선호 옵션 탑재" 등 [103]

# 참고문헌

아래는 본문에서 인용한 핵심 자료의 서지 정보(가능한 경우 DOI 포함)이다. 각 항목의 링크는 인용 표시를 통해 제공된다.


- Rosen, S. (1974). *Hedonic Prices and Implicit Markets: Product Differentiation in Pure Competition*. DOI: 10.1086/260169. [62]
- Akerlof, G. A. (1970). *The Market for "Lemons": Quality Uncertainty and the Market Mechanism*. DOI: 10.2307/1879431. [104]
- 송정석·신준호·이동준 (2020). 미국 중고차 가격의 결정 요인에 대한 실증연구. DOI: 10.17825/klr.2020.30.6.105. [64]
- Sharma, J. et al. (2024). *Developing a used car pricing model applying MARS*. [12]
- Huang, G., Liu, H., Luo, H. (2021). *Vehicle History Reports and the Efficiency of the Used-Car Retail Market*. DOI: 10.2139/ssrn.3976378. [49]
- CARFAX (2025). Accident history and used car price impact(기사/가이드). [68]
- 국토교통부 고시/서식(별지 제82호). 중고자동차성능·상태점검기록부(자동차가격조사·산정 선택). [71]
- 보험연구원(KIRI) (2024). 자동차 성능·상태점검 책임보험 현황과 과제. [55]
- 정민수(2022, KAIST). 모빌리티 시장 변화에 따른 상용 목적 차량의 잔존가치 요인 연구. [53]
- Englmaier, F., Schmöller, A., Stowasser, T. (2018). *Price Discontinuities in an Online Market for Used Cars*. DOI: 10.1287/mnsc.2016.2714. [34]
- Cox Automotive/Manheim. *Manheim Used Vehicle Value Index Summary Methodology* (outlier 제거, mileage 조정, X-13ARIMA-SEATS). [76]
- J.D. Power (2026). *U.S. ALG Residual Value Awards* (잔존가치 영향요인 개요). [78]
- Busse, M. R. et al. (2009). *The Differential Effect of Gasoline Prices on New and Used Automobile Markets*. NBER Working Paper. [96]
- National Institute of Standards and Technology (NIST). *Engineering Statistics Handbook: Measures of Location / Winsorized mean* 설명. [81]
- Tversky, A., Kahneman, D. (1974). *Judgment under Uncertainty: Heuristics and Biases*. DOI: 10.1126/science.185.4157.1124. [82]
- Schweinsberg, M. et al. (2023). *How buyer offers impact sale price and impasse risk in 26 million eBay negotiations*. DOI: 10.1073/pnas.2218582120. [84]
- KAMA 웹진(2017). 이전등록/거래 구조 해설. [88]
- 대한상공회의소 이슈페이퍼(2024). 국내 중고차 거래 규모/시장 추정(국토부 통계 인용). [90]


---


[1] [2] [6] [62] Hedonic Prices and Implicit Markets: Product Differentiation ...
https://www.journals.uchicago.edu/doi/10.1086/260169?utm_source=chatgpt.com

[3] [43] [63] [72] [74] [85] [104] The market for lemons
https://www.sfu.ca/~wainwrig/Econ400/akerlof.pdf?utm_source=chatgpt.com

[4] [16] [35] [40] [67] [76] [80] [93] [97] [98] site.manheim.com
https://site.manheim.com/wp-content/uploads/sites/2/2024/02/Used-Vehicle-Summary-Methodology.pdf

[5] [33] Price Discontinuities in an Online Market for Used Cars
https://ideas.repec.org/a/inm/ormnsc/v64y2018i6p2754-2766.html

[7] [17] [20] [21] [36] Insights on vehicle life history from a large data set of used car sales
https://eprints.whiterose.ac.uk/id/eprint/229963/1/UTSG_2025_Used_Cars%20v2.pdf

8 23 29 38 56 Search for an affordable clean car: Pricing of conventional and clean automobiles - ScienceDirect
https://www.sciencedirect.com/science/article/abs/pii/S1361920923001359

9 18 34 59 99 Price Discontinuities in an Online Market for Used Cars
https://pubsonline.informs.org/doi/10.1287/mnsc.2016.2714?utm_source=chatgpt.com

10 27 28 57 Determinants of Used Car Prices
https://dspace.cuni.cz/bitstream/handle/20.500.11956/182505/120444830.pdf?sequence=1&utm_source=chatgpt.com

11 44 45 47 48 71 102 law.go.kr
https://www.law.go.kr/flDownload.do?flNm=%5B%EB%B3%84%EC%A7%80+%EC%A0%9C82%ED%98%B8%EC%84%9C%EC%8B%9D%5D+%EC%A4%91%EA%B3%A0%EC%9E%90%EB%8F%99%EC%B0%A8%EC%84%B1%EB%8A%A5%E3%86%8D%EC%83%81%ED%83%9C%EC%A0%90%EA%B2%%EC%84%A0%ED%83%9D%29%0A&flSeq=82551573

12 30 41 52 58 65 73 75 Developing a used car pricing model applying Multivariate Adaptive regression Splines approach - ScienceDirect
https://www.sciencedirect.com/science/article/abs/pii/S0957417423017797

13 53 DSpace at KOASAS: 모빌리티 시장 변화에 따른 상용 목적 차량의 잔존가치 요인 연구
https://koasas.kaist.ac.kr/handle/10203/309605

14 22 49 50 51 54 70 87 101 Can You Judge a Car by Its History? Vehicle History Reports and the Efficiency of the Used-Car Retail Market by Guofang Huang, Haiyan Liu, Hong Luo :: SSRN
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3976378

15 25 66 77 91 103 Machine learning for predicting used car resale prices using granular vehicle equipment information - ScienceDirect
https://www.sciencedirect.com/science/article/pii/S0957417424025077

19 24 39 64 미국 중고차 가격의 결정 요인에 대한 실증연구
https://www.kci.go.kr/kciportal/ci/sereArticleSearch/ciSereArtiView.kci?sereArticleSearchBean.artiId=ART002675714

26 79 96 nber.org
https://www.nber.org/system/files/working_papers/w15590/w15590.pdf

31 32 60 University of Cape Town
https://open.uct.ac.za/bitstreams/471952ae-358d-4a4f-9283-413683788269/download?utm_source=chatgpt.com

37 81 83 1.3.5.1. Measures of Location
https://www.itl.nist.gov/div898/handbook/eda/section3/eda351.htm

42 68 Don’t Let Accident Reports Steer You Away From a Used Car | CARFAX
https://www.carfax.com/buying/buying-a-used-car-that-has-been-in-an-accident

46 중고차 성능·상태 점검 - 성능·상태 점검자 교육
https://www.kaiwa.org/inspection?utm_source=chatgpt.com

55 61 89 kiri.or.kr
https://www.kiri.or.kr/report/downloadFile.do?docId=535939

69 84 100 How buyer offers impact sale price and impasse risk in 26 ...
https://www.pnas.org/doi/10.1073/pnas.2218582120?utm_source=chatgpt.com

78 jdpower.com
https://www.jdpower.com/sites/default/files/file/2026-01-20/2026005%20U.S.%20ALG%20Residual%20Value%20Awards_0.pdf

82 Judgment under Uncertainty: Heuristics and Biases
https://www.science.org/doi/10.1126/science.185.4157.1124?utm_source=chatgpt.com

86 hbs.edu
https://www.hbs.edu/ris/Publication%20Files/16-027_1e5317c9-b364-4b55-a90d-fd32fbee167b.pdf

88 KAMA 웹진
https://www.kama.or.kr/jsp/webzine/201703/pages/report_02.jsp

90 kocham.org
https://kocham.org/wp-content/uploads/
2024/12/%EC%9D%B4%EC%8A%88%ED%8E%98%EC%9D%B4%ED%8D%BC_2024-13_%EC%A4%91%EA%B3%A0%EC%B0%A8_%EC%88%98%EC%B6%9C_%

92 Used Car Price Trends - CarGurus Pricing Index
https://www.cargurus.com/research/price-trends?utm_source=chatgpt.com

94 Robust Estimation of a Location Parameter
https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-35/issue-1/Robust-Estimation-of-a-Location-Parameter/10.1214/aoms/1177703732.full?utm_source=chatgpt.com

95 Fixed-effects Hedonic Price Model for Statistical Value of ...
https://www.tandfonline.com/doi/abs/10.1080/01441640600602336?utm_source=chatgpt.com